

Reporte Metodológico — Reconstrucción de la Sub-pregunta Q3

Documentación completa del proceso: de la limitación original (ausencia de semilla fija) al sistema final de clasificación por 5 ejes de contenido — Biomaterial Scaffold Design for Tissue Engineering

1. Contexto y motivación de la reconstrucción

El análisis original de Q3 (Sección 4 del paper) usó UMAP + HDBSCAN para modelado de tópicos, seguido de K-means para agrupar esos tópicos en K=5 macro-categorías temáticas, sin fijar una semilla aleatoria en ningún paso. El paper ya reconoce esto como limitación explícita: un re-run no garantiza tópicos ni agrupaciones idénticas. Se decidió reconstruir el pipeline completo en Google Colab, con semilla fija, para (i) evaluar la robustez del hallazgo central (hidroxiapatita=bioactividad, PCL=soporte mecánico) ante variación metodológica, y (ii) corregir debilidades detectadas en el diseño original del análisis de agrupamiento.

2. Fases del pipeline reconstruido

Fase 0. Instalación de librerías (sentence-transformers, BERTopic, UMAP, scikit-learn, transformers, Pillow fijado en $\geq 12.2.0$ por conflicto de versión conocido).

Fase 0.5. Conversión de los 78 PDFs (subidos en 4 archivos .zip) a texto plano con pdfplumber.

Fase 1. Segmentación del texto completo en fragmentos de ~180 palabras (límite de 512 tokens de BioBERT).

Fase 2. Generación de embeddings con BioBERT (pritamdeka/BioBERT-mnli-snli-scinli-scitail-mednli-stsb).

Fase 3. Modelado de tópicos: UMAP + HDBSCAN vía BERTopic, con búsqueda sistemática de hiperparámetros validada con DBCV — la métrica correcta para clustering basado en densidad, en vez de silueta directa.

Fase 4. Auditoría y limpieza manual de tópicos de ruido (listas bibliográficas, licencias editoriales, fragmentos OCR corruptos, declaraciones de autoría/financiamiento).

Fase 5. Clasificación por 5 ejes de contenido con regla de exclusión por predominio metodológico (reemplaza el K-means original).

Fase 5.5. Normalización de sinónimos de material en el texto, antes del NER.

Fase 6. Extracción de entidades biomédicas (NER) con d4data/biomedical-ner-all, sobre el texto ya normalizado.

Fase 7. Construcción de una red de co-ocurrencia por cada uno de los 5 ejes (no por macro-grupo excluyente).

Fase 8. Cálculo de centralidad de grado e intermediación por red.

Fase 9 / 9.5. Visualización y exportación de cada red a formato .gexf para análisis en Gephi.

3. El problema de la silueta y el abandono de K-means

La silueta de los 57-60 tópicos individuales generados por HDBSCAN (Fase 3) fue de 0.54 — una separación razonablemente buena. Sin embargo, al forzar esos tópicos dentro de K macro-categorías excluyentes mediante K-means (el enfoque original del paper), la silueta caía drásticamente a 0.12. Este contraste (0.54

→ 0.12) es evidencia empírica de que la macro-agrupación exclusiva no respeta la estructura natural de los datos.

Por esta razón se abandonó el paso de K-means por completo, en favor de un sistema de clasificación por ejes no excluyentes, que opera directamente sobre los tópicos de HDBSCAN sin ningún paso adicional de clustering — preservando la separación original de 0.54 en vez de degradarla a 0.12.

4. El sistema de 5 ejes: qué son y su justificación

En vez de asignar cada tópico a una única macro-categoría excluyente, se clasifica cada tópico simultáneamente en 5 ejes de contenido no excluyentes, reflejando que un mismo estudio real suele hablar de material, estrategia, propiedad, función y aplicación al mismo tiempo.

Eje	Qué captura
1. Material / Composición	Matriz, refuerzo y agente bioactivo del sistema
2. Estrategia de Fabricación	Cómo se construyó o modificó el andamio
3. Propiedad de Ingeniería	Características físicas/mecánicas medibles
4. Función Biológica	Efecto o actividad biológica producida
5. Aplicación Tisular	Tejido u órgano objetivo

4.1 Justificación de por qué estos ejes y no otros

Precedente en la literatura: clasificar biomateriales por material, fabricación y función es una convención reconocida en revisiones del campo (ej. Collins et al. 2021).

Consistencia interna con el propio paper: Material y Estrategia ya son el eje central de Q1 y Q2; Aplicación Tisular y Función Biológica ya están implícitos en la Tabla S3.

Justificación empírica: los ejes se verificaron contra las palabras clave reales de los tópicos, no fueron asignados a ciegas.

4.2 Etiqueta auxiliar: Técnica de Ensayo

Vocabulario puramente procedimental (SEM, FTIR, MTT, PBS, incubación, ANOVA) se trata como etiqueta auxiliar, no como sexto eje de contenido.

5. Regla de exclusión por predominio metodológico

Para decidir si un tópico es contenido temático genuino o ruido metodológico/bibliográfico, se calculó un índice de predominio metodológico sobre los pesos c-TF-IDF que BERTopic ya calcula para cada tópico (no recalculados aparte):

$$S_met(t) = [\sum cTFIDF(w,t) \text{ para } w \text{ en Metodología}] / [\sum cTFIDF(w,t) \text{ para } w \text{ en Metodología} \cup \text{Contenido}]$$

Condición	Categoría	Decisión
$S_met \geq 0.70$ y vocab. metodológico en $\geq 60\%$ de fragmentos	Metodológico dominante	Excluir automáticamente
$S_met < 0.40$	Contenido temático	Conservar automáticamente
$0.40 \leq S_met < 0.70$	Mixto metodológico-temático	Revisión manual

Dos categorías adicionales se detectan aparte del índice S_met : **bibliográfico/editorial** (≥ 3 de las 10 palabras clave principales son nombres de autores recurrentes o fragmentos de cita) y **ruido OCR** (patrones de letras duplicadas en las palabras clave, ej. "tthhee").

Resultado real al aplicar la regla a los 57 tópicos genuinos: 49 contenido temático, 5 mixto (revisión manual), 2 bibliográfico/editorial, 1 ruido OCR, 0 metodológico dominante puro.

6. Corrección del NER: normalización de sinónimos de material

Problema detectado: en las primeras redes de co-ocurrencia, hidroxiapatita aparecía con 0 conexiones. Una auditoría de texto reveló que el material se mencionaba 665 veces en el corpus, repartidas en 13 variantes de escritura distintas (hap: 232, nhap: 147, hydroxyapatite: 111, n-ha: 101, nha: 57, entre otras) — ninguna variante individual acumulaba suficiente co-ocurrencia repetida con otras entidades para superar el umbral mínimo de la red (peso ≥ 2).

Solución aplicada: normalización del texto ANTES de la extracción NER (no después, sobre las entidades ya extraídas) — se insertó una fase nueva (5.5) que reemplaza todas las variantes conocidas por un nombre canónico único, usando expresiones regulares con límites de palabra estrictos para evitar falsos positivos (ej. "happened" no debe fusionarse con "hap").

Por qué pre-procesar en vez de post-procesar: corregir el texto de entrada asegura que el NER nunca tenga la oportunidad de extraer una variante no unificada, resolviendo el problema de raíz en vez de depender de que un diccionario posterior adivine correctamente todos los alias generados.

Naturaleza de la técnica: la normalización de sinónimos antes de NER ("entity normalization") es una práctica estándar en minería de texto biomédico, no una técnica desarrollada en este proyecto. El hallazgo propio de este trabajo es diagnóstico: la detección de que este corpus específico requería dicha normalización, y la cuantificación de su magnitud (13 variantes, 665 menciones).

Resultado: tras la corrección, hidroxiapatita pasó a ser, en varios de los 5 ejes, el nodo más central de la red — incluso superando a PCL en Material/Composición — revirtiendo por completo el resultado inicial distorsionado.

Limitación reconocida: la normalización no es exhaustiva; se detectó posteriormente al menos una variante adicional sin cubrir ("nano ha", con espacio) en el Eje de Material, lo que sugiere que la centralidad real de

hidroxiapatita en ese eje específico aún podría estar ligeramente subestimada.

7. Síntesis del proceso completo

La reconstrucción de Q3 partió de una limitación reconocida (ausencia de semilla fija) y, en el proceso, identificó y corrigió 2 debilidades metodológicas adicionales no documentadas en la versión original del paper: (1) la macro-agrupación K-means degradaba artificialmente la separación de los tópicos (0.54 → 0.12), resuelto reemplazándola por clasificación multi-eje; y (2) el NER fragmentaba el nombre de hidroxiapatita en múltiples variantes no unificadas, resuelto mediante normalización de texto previa a la extracción de entidades. El resultado final —5 redes de co-ocurrencia, una por eje— reproduce y refuerza el hallazgo central del paper (asociación de hidroxiapatita con bioactividad y PCL con soporte mecánico) usando una arquitectura metodológica más defendible que el diseño original.